

Documento técnico — Ventas por sucursal y ventana con Kafka, Beam y Flink

Proyecto integrador · Streaming de datos y sus aplicaciones · Maestría en Inteligencia Artificial, FPUNA · Docente: Rodrigo Parra, M.Sc. · Septiembre de 2026

Integrantes y contribuciones: ver [integrantes.md](#).

1. Problema, usuarios y decisiones que habilita


Una cadena minorista opera terminales de punto de venta (POS) en seis sucursales. Cada venta confirmada produce un evento `sale.confirmed`. Los terminales siguen vendiendo sin conectividad y reenvían en lote al reconectarse, y un POS que no recibe la confirmación del broker reenvía el mismo evento. Por eso el flujo real llega **desordenado**, con **retrasos** de segundos a minutos y con **duplicados**.

Pregunta de negocio: **¿cuánto vendió cada sucursal en cada ventana de tiempo (monto total en guaraníes y cantidad de tickets), atribuyendo cada venta al momento del pago?**

Usuario del resultado	Qué necesita	Cómo lo obtiene
Tablero de gerencia	Ver la ventana en curso con pocos segundos de demora; acepta valores provisionales etiquetados.	Panes <code>EARLY</code> cada 10 s de processing time, <code>pane_timing</code> visible en la fila.
Reporte comparativo por sucursal y hora	Cada venta en la ventana en que ocurrió; tolera correcciones durante un período acotado.	Tiempo de evento, pane <code>ON_TIME</code> y panes <code>LATE</code> durante la lateness permitida; upsert por clave.
Conciliación contable	No perder ninguna venta, aunque llegue fuera del horizonte.	DLQ <code>ventas.dlq.v1</code> con <code>motivo=demasiado_tardio</code> , monto y <code>event_id</code> .
Operación del pipeline	Ver producción, consumo, procesamiento y errores.	Logs etiquetados del productor y del materializador, métricas Beam, UI de Flink, tabla <code>rechazos</code> .

Escala de la demostración: ventana de 60 s y lateness de 30 s. Los mismos parámetros (`WINDOW_SECONDS`, `ALLOWED_LATENESS_SECONDS`, `EARLY_FIRING_SECONDS`) valen 3600 / 1800 / 300 en producción, donde la ventana es la hora comercial.

2. Arquitectura



Componente	Tecnología	Función
Productor sintético	Python 3.12, confluent-kafka	Genera ventas reproducibles (semilla fija) para 6 sucursales × 3 POS y, de forma controlada, duplicados, desorden, tardíos aceptables, demasiado tardíos e inválidos. Modo demo (guion determinista) y modo continuo (tasas configurables).
Kafka	Apache Kafka 4.1.1, KRaft, un broker	Log durable de entrada (ventas.confirmadas.v1), salida compactada (ventas.por_ventana.v1) y DLQ (ventas.dlq.v1).
Pipeline	Apache Beam 2.74 (Python SDK)	Lectura con KafkaIO, validación con salidas laterales, asignación de tiempo de evento, ventana fija, CombinePerKey con deduplicación, formateo y escritura con KafkaIO.
Runner	Flink 1.19.3 (JobManager + 1 TaskManager con 4 slots), Beam Job Server beam_flink1.19_job_server:2.74.0	PortableRunner en modo streaming , paralelismo 2 (los 2 slots restantes permiten ejecutar el smoke test en paralelo), checkpoints EXACTLY_ONCE cada 30 s, estado en memoria (hashmap). Los SDK harness (Java para KafkaIO, Python para el pipeline) corren como procesos dentro del TaskManager (environment_type=PROCESS), sin Docker-in-Docker.
Materializador	Python, SQLite	Consume agregados y DLQ; INSERT ... ON CONFLICT DO UPDATE por aggregate_id condicionado a pane_index creciente; commit de offsets después de persistir.
Orquestación	Docker Compose, Makefile	make up / demo / reporte / smoke / down.

Flujo de un evento: el POS confirma el pago → el productor publica en `ventas.confirmadas.v1` con clave `store_id` y `timestamp = event_time` → KafkaIO lo lee y deriva el watermark del timestamp → `ParsearYValidar` lo decodifica (o lo desvía a la DLQ) → `asignar_tiempo_evento` fija el timestamp Beam en `event_time` → `FixedWindows(60 s)` lo ubica en su ventana → `CombinePerKey` lo suma una sola vez por `event_id` → cada disparo del trigger produce un pane con `aggregate_id`, `pane_index` y `pane_timing` → `WriteToKafka` lo publica en `ventas.por_ventana.v1` → el materializador hace upsert en SQLite.

3. Contrato de eventos, tópicos, claves, particiones y esquema de salida

3.1 Evento de entrada (`ventas.confirmadas.v1`)

```
{
  "schema_version": 2,
  "event_id": "S2-pos-01-000123",
  "event_type": "sale.confirmed",
  "event_time": "2026-09-21T14:23:05.120Z",
  "key": "S2",
  "payload": {
    "store_id": "S2", "pos_id": "pos-01", "ticket_id": "T-S2-pos-01-000123",
    "amount_gs": 415000, "items": 3, "payment": "card", "channel": "store"
  }
}
```

Campo	Decisión y justificación
event_id	store-pos-secuencia, generado en el POS antes de publicar: estable ante reintentos (el reenvío lleva el mismo id), único (la secuencia es por terminal) y legible. Es la clave de deduplicación.
key	store_id. Es la clave de negocio de la agregación y la clave de partición de Kafka: todos los eventos de una sucursal caen en la misma partición y se leen en orden de publicación.
event_time	Reloj del POS al confirmar el pago, ISO-8601 UTC. Es el tiempo de evento; el tiempo de procesamiento (ingest_time, emitted_at) se registra aparte y solo se usa para observabilidad y triggers tempranos.
payload	Lo necesario para validar (monto > 0, ítems > 0, medio de pago conocido, store_id coherente con key) y calcular (monto, ítems, medio de pago).
schema_version	Evolución aditiva y compatible hacia atrás : v2 agrega payload.channel (opcional, por defecto store). El decodificador acepta v1 y v2, completa valores por defecto (upgrade_evento) y rechaza versiones mayores (van a la DLQ con version_no_soportada). La versión viaja también como cabecera Kafka para filtrar sin deserializar. El productor emite ~20 % de eventos v1 para ejercitar la compatibilidad.

Validación (contratos.validar_evento) y plausibilidad del reloj (ParsearYValidar): event_time más de 2 min en el futuro o más de 24 h en el pasado se rechaza (reloj_futuro / reloj_pasado) para que un reloj defectuoso no contamine el watermark ni las ventanas.

3.2 Tópicos

Tópico	Clave	Particiones	Configuración	Justificación
ventas.confirmadas.v1	store_id	4	retention.ms=24h, timestamp de registro = event_time	Orden: Kafka garantiza orden solo dentro de la partición; con store_id los eventos de una sucursal se leen en el orden en que se publicaron, lo que mantiene acotado el desorden que Beam debe absorber y permite en el futuro procesamiento con estado por sucursal. Paralelismo: 4 particiones fijan el máximo de lectores paralelos; el job usa paralelismo 2 (2 particiones por subtarea) y puede subir a 4 sin repartición. Skew: con 6 claves y pesos 30/25/15/15/10/5 % el reparto por murmur2(store_id) mod 4 es desigual: en la demostración la partición 2 (S1+S3) recibió el 47 % de los mensajes y la partición 3 (S5) el 8 % (evidencia/05_...). Es aceptable para este volumen; si una sucursal dominara se pasaría a la clave store_id pos_id (18 claves, conserva el orden por terminal), o se aumentaría el número de particiones antes de cargar datos.

Tópico	Clave	Particiones	Configuración	Justificación
ventas.por_ventana.v1	aggregate_id = store_id window_start	4	cleanup.policy=compact	Cada pane es una nueva versión del mismo resultado; la compactación conserva el último valor por clave, de modo que el tópico se comporta como una tabla reconstruible (vista materializada). Un consumidor nuevo obtiene el estado completo leyendo desde el inicio.
ventas.dlq.v1	key original o event_id	2	retention.ms=7d	Mensajes inválidos y demasiado tardíos con motivo, detalle, rechazado_en y el mensaje original, para revisión y conciliación.

Productor: `enable.idempotence=true`, `acks=all`, `linger.ms=20`, compresión `snappy`. Los reintentos del cliente no duplican ni reordenan dentro de la partición. El registro lleva `timestamp = event_time` porque KafkaIO deriva de él el watermark.

3.3 Esquema de salida (ventas.por_ventana.v1 y tabla ventas_por_ventana)

```

{
  "schema_version": 1,
  "aggregate_id": "S2|2026-09-21T14:23:00.000Z",
  "store_id": "S2",
  "window_start": "2026-09-21T14:23:00.000Z",
  "window_end": "2026-09-21T14:24:00.000Z",
  "ticket_count": 12, "total_amount_gs": 4280000, "items": 31, "avg_ticket_gs": 356667,
  "by_payment_gs": {"card": 2100000, "cash": 1680000, "qr": 500000},
  "duplicates_discarded": 1,
  "pane_index": 2, "pane_timing": "LATE", "is_first": false, "is_last": false,
  "emitted_at": "2026-09-21T14:24:07.512Z"
}

```

`aggregate_id` es la clave estable del resultado; `pane_index` ordena las versiones; `pane_timing` dice cómo debe leerse el valor (provisional, cerrado a tiempo o corregido); `duplicates_discarded` evidencia la deduplicación.

4. Política temporal: ventanas, watermark, lateness, triggers y acumulación

Pregunta	Decisión
Qué	Tickets, monto total, ítems, ticket promedio y monto por medio de pago, por sucursal. <code>CombinePerKey</code> con un <code>CombineFn</code> incremental (<code>VentasPorSucursalCombineFn</code>).

Pregunta	Decisión
Dónde (ventana)	FixedWindows(60 s) alineada al minuto, intervalos [inicio, fin). La pregunta es "qué ocurrió en cada período" y los períodos deben ser comparables entre sucursales y días. Se descartó la ventana deslizante (cada evento en varias ventanas, no coincide con el período del reporte) y la de sesión (no es la pregunta; exige fusiones).
Cuándo (watermark)	KafkaIO con create_time_policy: el watermark de cada partición es el máximo timestamp de registro (event_time) observado y, si la partición está ociosa, avanza con el reloj del sistema; el watermark del job es el mínimo entre particiones. Es heurístico: no promete que no lleguen datos más antiguos, y por eso existe la lateness.
Cuándo (triggers)	AfterWatermark(early=AfterProcessingTime(10 s), late=AfterCount(1)): pane EARLY cada 10 s de processing time mientras la ventana está abierta (tablero), pane ON_TIME cuando el watermark cruza el fin, un pane LATE por cada evento que llega dentro de la lateness.
Lateness permitida	allowed_lateness=30 s (30 min en producción): el estado de la ventana se conserva hasta fin + 30 s; cada tardío corrige el resultado. Supera el p99 asumido de la cola de terminales offline y acota el estado a dos ventanas abiertas por sucursal.
Cómo (acumulación)	ACCUMULATING: cada pane trae el total conocido hasta el momento. Permite un upsert simple en el sink (el último pane es la verdad) y evita retractaciones.
Demasiado tardíos	Beam descarta en silencio lo que llega después de fin + lateness. Para no perderlo, ParsearYValidar mantiene un watermark heurístico local (máximo event_time válido visto por el worker) y desvía a la DLQ con motivo=demasiado_tardio lo que queda más de ventana + lateness por detrás. Es una aproximación: la autoridad es el watermark de Beam; un evento en la zona gris puede ser descartado por Beam sin pasar por la DLQ (límite declarado en la sección 7).

Clasificación de un evento al llegar, respecto del watermark WM y de su ventana [ini, fin):

Categoría	Condición	Tratamiento
A tiempo (incluye desordenados)	WM < fin	Se suma; aparece en EARLY y ON_TIME.
Tardío	fin ≤ WM < fin + 30 s	Se suma y dispara un pane LATE (pane_index mayor).
Demasiado tardío	WM ≥ fin + 30 s	DLQ con demasiado_tardio (heurístico) o descarte por Beam.
Duplicado	event_id ya en el acumulador de la ventana	No altera el total; incrementa duplicates_discarded.
Reloj implausible	event_time > ahora + 2 min o < ahora - 24 h	DLQ; no participa del watermark.

Comportamientos observados del runner (evidencia en evidencia/03_materializador.txt):

- **Pane de cierre.** Tanto el DirectRunner (pruebas) como Flink emiten, al expirar la ventana (fin + lateness), un pane adicional con timing LATE e idéntico contenido al último; el sink lo absorbe por idempotencia (panes_recibidos lo cuenta).
- **Retraso del watermark.** En Flink el watermark derivado por KafkaIO avanza entre 10 y 25 s por detrás del reloj de pared con tráfico continuo (el pane ON_TIME de la ventana [23:58, 23:59] se emitió a las 23:59:2x) y hasta 80 s cuando el tópico queda ocioso. Es la razón por la que el guion de demostración envía la venta tardía después de observar el pane ON_TIME en el tópico de salida, en lugar de fiarse del reloj. En producción (ventana de 60 min) este retraso es irrelevante.
- **Panes vacíos fuera de orden.** Si el watermark salta de golpe más allá de fin + lateness (por ejemplo, tras un período ocioso), Flink puede emitir para cada clave un pane ON_TIME vacío con pane_index = 0 después del pane real; al terminar un job acotado (smoke test) el pane vacío llega incluso con el mismo pane_index que el real. La versión monótona (ticket_count,

`pane_index`) del sink los descarta (`IGNORADO` en el log); es un caso real donde la idempotencia del sink evita corromper el resultado.

5. Deduplicación, idempotencia y semántica de entrega

Deduplicación. El acumulador del `CombineFn` guarda, por `event_id`, el monto, los ítems y el medio de pago ya sumados; un `event_id` repetido no altera el total y se cuenta en `duplicates_discarded`. Al fusionar acumuladores parciales (*combiner lifting* en Flink) los solapamientos se descuentan.

Horizonte: el de la ventana, `fin + lateness` (90 s en la demo, 90 min en producción), que es exactamente el período durante el cual un duplicado podría alterar un resultado ya publicado. Un duplicado que llega después del horizonte cae en la categoría "demasiado tardío" y no toca el resultado.

Idempotencia de la salida. Claves estables en dos niveles: en Kafka, el tópico compactado conserva el último pane por `aggregate_id`; en SQLite, el `upsert` solo aplica si la versión del pane no retrocede, con versión = (`ticket_count`, `pane_index`). En modo `ACCUMULATING` y sin retractaciones el conteo de una ventana nunca decrece, así que es un reloj lógico más robusto que `pane_index` solo: descarta panes viejos reproducidos, los panes vacíos con `pane_index` repetido que Flink emite al expirar una ventana (observados en el smoke test) y sobrevive a un reinicio del pipeline que reinicie los índices. Releer el tópico desde el inicio, recibir un pane dos veces o recibir panes fuera de orden deja la tabla en el mismo estado final (`test_materializador.py` y `evidencia/07_idempotencia_replay.txt`).

Semántica alcanzada por tramo (sin sobreprometer):

Tramo	Garantía	Mecanismo	Lo que no cubre
Productor → Kafka	Al menos una vez sin duplicados por reintento del cliente	<code>enable.idempotence</code> , <code>acks=all</code>	Reenvíos de la aplicación (POS que reenvía tras perder el ack): llegan como duplicados lógicos con el mismo <code>event_id</code> y los resuelve Beam.
Kafka → Beam/Flink	Al menos una vez; estado consistente con checkpoints <code>EXACTLY_ONCE</code> de Flink cada 30 s	Offsets como parte del checkpoint; <code>auto.offset.reset=earliest</code> ; lectura vía SDF	Tras un reinicio se reprocesan los registros posteriores al último checkpoint; la deduplicación por <code>event_id</code> dentro del horizonte y la idempotencia del sink absorben la repetición. Probado reiniciando el TaskManager con el job en curso (<code>evidencia/10_tolerancia_fallos.txt</code>): Flink restauró el checkpoint y el flujo continuó.
Beam → Kafka (salida)	Al menos una vez	<code>WriteToKafka</code> con productor idempotente, sin transacciones Kafka	El mismo pane puede publicarse dos veces tras un fallo; es inocuo porque la clave y el <code>pane_index</code> son estables.
Kafka (salida) → SQLite	Efectivamente una sola vez	Upsert por <code>aggregate_id</code> con versión (<code>ticket_count</code> , <code>pane_index</code>) monótona; commit de offset después de persistir	Si el proceso muere entre el upsert y el commit, el mensaje se reprocesa y el upsert es un no-op.

No se afirma exactly-once end-to-end. Lo que se garantiza es que el estado final de `ventas_por_ventana` es el mismo con o sin reentregas, reinicios o relecturas, y que ninguna venta válida se pierde en silencio: o está en el resultado o está en la DLQ con su motivo.

6. Pruebas y evidencia

Nivel	Herramienta	Escenarios cubiertos
Unitarias de contrato y lógica	pytest	v1 → v2, nueve motivos de rechazo estables, CombineFn con duplicados y fusión de acumuladores, sink idempotente, determinismo del productor.
Ventanas y tiempo de evento	TestPipeline + TestStream (DirectRunner streaming)	Pane ON_TIME al cruzar el watermark; evento tardío dentro de la lateness → pane LATE con el total corregido; evento fuera de la lateness → descartado (sin pane); duplicado tardío → pane LATE con el mismo total y duplicates_discarded incrementado; evento desordenado dentro de la ventana → absorbido sin pane extra.
Salidas laterales	TestPipeline (lote)	JSON corrupto, reloj futuro y payload incompleto van a invalido; un evento 210 s por detrás del máximo visto va a muy_tardio; el que está a 89 s (dentro del horizonte de 90 s) se agrega.
Smoke end-to-end	scripts/smoke.py sobre Docker	Tópicos efímeros; 50 ventas + 3 duplicados + 1 demasiado tardío + 3 inválidos; pipeline acotado (max_num_records); materialización; verifica tickets únicos = 50, duplicados descartados = 3, DLQ con 1 demasiado_tardio y 3 rechazos de contrato.
Demostración	make up, make demo, make reporte	Guion determinista con siete fases (normales, duplicados, desorden, tardío, demasiado tardío, inválidos, normales) observado en logs, UI de Flink y SQLite. Resultado de la corrida documentada: 302 mensajes publicados; 18 filas de salida; S1 23:58 pasó de 35 tickets (ON_TIME) a 36 (LATE) por la venta tardía; 3 duplicados descartados; 7 rechazos con motivo, incluido el demasiado tardío.
Tolerancia a fallos	Reinicio del TaskManager en caliente	El job se restauró desde el último checkpoint y siguió materializando ventanas; los panes reemitidos no alteraron el estado.
Idempotencia	Segundo consumidor con grupo nuevo	Releer ambos tópicos desde el inicio produce exactamente el mismo estado (18 filas, 7 rechazos) aunque la compactación ya eliminó parte de los panes.

La evidencia de la ejecución real (salidas capturadas sin edición) está en [evidencia/](#); el archivo `evidencia/README.md` la describe.

7. Límites conocidos, supuestos y mejoras

Supuestos: relojes de los POS sincronizados por NTP (desvío < 30 s); retardo normal POS → Kafka de segundos; cola de terminales offline por debajo de la lateness en el p99; una sola zona horaria; solo ventas confirmadas (anulaciones y devoluciones quedan fuera, por lo que los totales de una ventana solo crecen).

Límites:

- Un broker, un JobManager y un TaskManager, sin replicación ni alta disponibilidad; el estado de las ventanas está en memoria con checkpoints locales al contenedor. Un despliegue real usaría tres brokers con `min.insync.replicas=2`, RocksDB y checkpoints en almacenamiento durable.
- El productor sintético es reproducible pero no es un replay de datos históricos; el contrato y el pipeline no cambiarían con una fuente real.
- La clasificación de "demasiado tardío" en `ParsearYValidar` es heurística y local al worker (se reinicia con el proceso); Beam sigue siendo quien decide con su watermark y puede descartar sin pasar por la DLQ en la zona gris. La versión definitiva usaría el contador `droppedDueToLateness` del runner o un `DoFn` con estado y timers que conozca el watermark.
- `WriteToKafka` no usa transacciones Kafka: un pane puede publicarse dos veces tras un fallo (inocuo por idempotencia, pero visible en `panes_recibidos`).
- Los panes `EARLY` dependen del processing time; su cadencia no es reproducible entre ejecuciones (los `ON_TIME` y `LATE` sí lo son).

- SQLite es un sink de demostración; en producción sería una base con `UPSERT` nativo (PostgreSQL) o un almacén clave-valor alimentado por el tópico compactado.

Mejoras posibles: deduplicación con estado y timers y horizonte independiente de la ventana (`Deduplicate` de Beam); métricas exportadas a Prometheus/Grafana (retraso de ingesta, panes por tipo, rechazos por motivo); replay de un dataset histórico con control de velocidad; vista deslizante adicional para detectar picos; modelado de anulaciones con retractaciones o con montos negativos por `ticket_id`.

8. Reproducibilidad

Todo se ejecuta con Docker Compose desde el README: `make up` construye las imágenes (la de aplicación cachea el JAR del servicio de expansión de KafkaIO en tiempo de build; la de Flink incluye los SDK harness de Beam como procesos), crea los tópicos con sus configuraciones, envía el job y arranca el materializador. `make demo` reproduce siempre el mismo guion (semilla fija) y `make smoke` verifica automáticamente el recorrido completo. No hay pasos manuales.